

CG+ Gradientenverfahren

Gradientenverfahren am Beispiel Minimierung eines quadratischen Potentiales

- Minimierung eines Potentials / quadratisches Term eines LGS $\underline{A}\underline{x} = \underline{y} \Rightarrow f(\underline{x}) = \frac{1}{2} \underline{x}^T \underline{A} \underline{x} - \underline{y}^T \underline{x}$
- $\underline{A} \in \text{Sym}^+$ (symmetrisch positiv definit) \Leftrightarrow konkaves Potential $f(\underline{x})$
- Minimiere quadrat. Form \Leftrightarrow Residuum $\underline{\tau} = -\nabla f(\underline{x}) = \underline{y} - \underline{A}\underline{x}$ Lösung wenn $\underline{\tau} = \underline{0} \Rightarrow f(\underline{x}) = \underline{0}$

Iterationsgeschicht:

$$\underline{x}_{i+1} = \underline{x}_i + \alpha \underline{\tau}_i = \underline{x}_i - \alpha \nabla f(\underline{x}_i)$$

Wie groß darf die Schrittweite α sein?

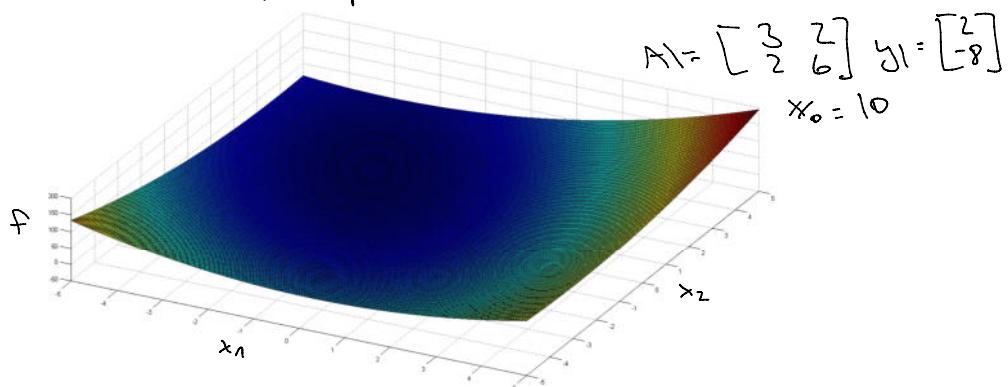
$$\min_{\alpha} f(\underline{x}_{i+1}) = \frac{\partial f(\underline{x}_{i+1})}{\partial \underline{x}_{i+1}} \cdot \underline{\alpha} = -\underline{\tau}_{i+1} \cdot \frac{\partial \underline{x}_{i+1}}{\partial \alpha} = -\underline{\tau}_{i+1} \cdot \underline{\tau}_i = 0$$

$\rightarrow \underline{\tau}_{i+1} \perp \underline{\tau}_i \rightarrow$ Orthogonalität der Abstiegsrichtungen

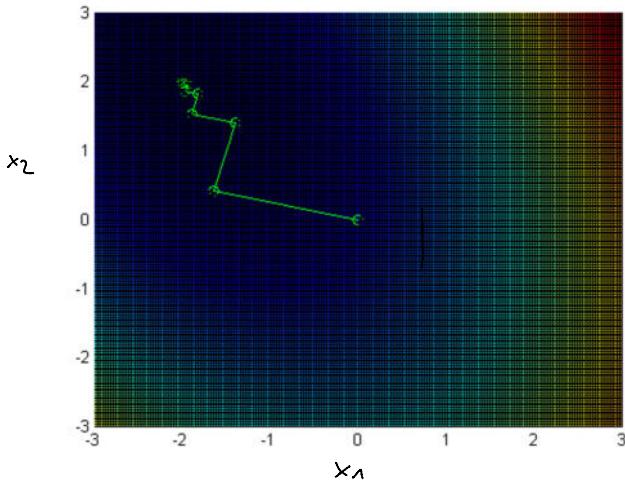
$$-\underline{\tau}_{i+1} \cdot \underline{\tau}_i = (\underline{A}(\underline{x}_i + \alpha \underline{\tau}_i) - \underline{y}) \cdot \underline{\tau}_i = 0$$

$$\rightarrow \alpha = \frac{(\underline{y} - \underline{A}\underline{x}_i) \cdot \underline{\tau}_i}{\underline{\tau}_i \cdot \underline{\tau}_i} = \frac{\underline{\tau}_i \cdot \underline{\tau}_i}{\underline{\tau}_i \cdot \underline{\tau}_i}$$

Contourplot



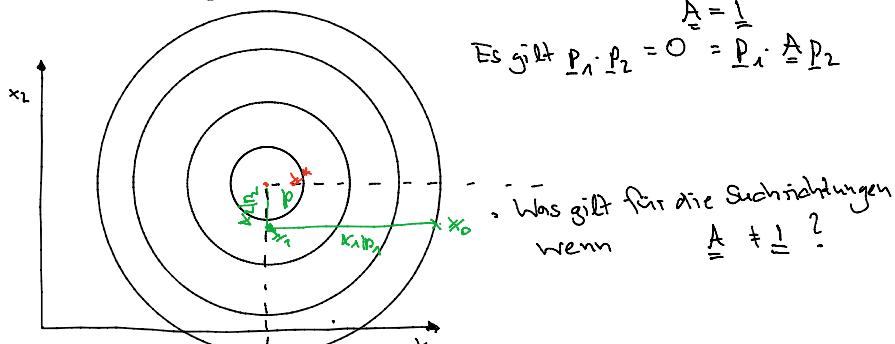
Schritte Gradientenverfahren \rightarrow Suchrichtungen werden mehrmals durchlaufen



CG-Verfahren:

- Lösen eines Gleichungssystems der Form $\underline{A}\underline{x} = \underline{y} \quad \underline{A} \in \text{Sym}^+, \lambda_i > 0$
- Besonders effizient für dünnbesetzte Matrizen / kleine Konditionszahlen \rightarrow Vor konditionieren
- Idee: Minimierung der skalaren quadratischen Form $f(\underline{x}) = \frac{1}{2} \underline{x}^T \underline{A} \underline{x} - \underline{y}^T \underline{x} = 0$
- Problem lösbar? \rightarrow Konvexität der skalaren Funktion $F \Leftrightarrow \underline{A} \in$ positiv definit Voraussetzung
- $\nabla^2 f(\underline{x}) = \frac{1}{2} (\underline{A}^T + \underline{A})$; \underline{A} muss positiv definit sein (Für NO-Problem positive Krümmung \rightarrow eindeutiges Minimum)
- $\nabla f(\underline{x}) = \frac{1}{2} (\underline{A}^T \underline{x} + \underline{A} \underline{x}) - \underline{y} = \underline{0}$ nur symmetrischer Teil von \underline{A} berücksichtigt $\rightarrow \underline{A} \in \text{Sym}$

- Analog zum Gradientenverfahren ergibt sich die Lösung als Linearkombination
$$x_k = x_0 + \sum_{i=1}^k x_i p_i$$
p_i bilden eine Basis eines über $\underline{\Delta}$ definierten Unterraumes
 \Rightarrow Jede beliebige Lösung kann durch Linearkombination der k-Suchrichtungen dargestellt werden
- Vorbereitung: Welche Eigenschaften können an die Suchrichtungen p_i gestellt werden?
 - Für $\underline{\Delta} = \underline{I}$ entspricht $f(x)$ einem Kreis (2D-Problem)
 - Ansatz: Wähle Suchrichtungen, so dass sie den Basisvektoren e_1, e_2 entsprechen $\Rightarrow x^* = x_0 + x_1 e_1 + x_2 e_2 = x_0 p_1 + x_2 p_2$
 - \Rightarrow für optimales gewähltes x_i sind max. 2 Iterationen bis zur Lösung notwendig



\Rightarrow Mache Suchrichtungen $\underline{\Delta}$ -orthogonal / konjugiert \Rightarrow $k =$ aktueller Rechenschritt

$$p_i \cdot \underline{\Delta} p_j = \delta_{ij} \quad i, j = 1 \dots k$$

Suchrichtungen der anderen Rechenschritte sind orthogonal zur Abbildung von $\underline{\Delta}$ auf $p_j \rightarrow p_i$ ist $\underline{\Delta}$ -orthogonal / konjugiert

- Für $\underline{\Delta} = \underline{I}$ gilt das Standardskalarprodukt
- Für $\underline{\Delta} \neq \underline{I}$ wird die Streckung/Stauchung/Drehung von p durch die Abbildung von $\underline{\Delta} p_j$ für das Skalarprodukt weiterführend
 \Rightarrow Skalarprodukt bzgl. eines $n \times n$ -euklidischen Raumes
- $\underline{\Delta} \in \text{sym} \rightarrow \underline{\Delta} = \underline{\lambda} \underline{I}^{-T} \rightarrow$ Abbildung von p_j auf Projektionen (Basis von $\underline{\Delta}$), Streckung, Stauchung von p_j über Eigenwerte λ_i
- Konvergenz in $\leq n$ Schritten $n =$ Dimension des Problems

Algorithmus (Gr-Verfahren Herleitung)

- Ansatz für Lösung: $x_k = x_0 + \sum_{i=1}^k x_i p_i$

$$\text{Residuum } r_k = y - \underline{\Delta} x_k = -\nabla f(x)$$

- gesucht Lösung x^* ; Startwert: x^0

- Ansatz für Abstiegsrichtung p_{k+1} : $p_{k+1} = I_k + \sum_{j=1}^k \beta_{j+1} p_j$

- Bestimmung optimale Schrittwerte x_i , $i = 1 \dots k$ $i \neq$ beliebigem Iterationsschritt

$$\text{minimiere } f(x_k) \rightarrow \min_{x_i} \left\{ f(x_k) = \frac{1}{2} x_k \cdot \underline{\Delta} x_k - y \cdot x_k \right\}$$

$$\Rightarrow \frac{\partial f(x_k)}{\partial x_k}, \frac{\partial x_k}{\partial x_i} = \nabla f(x_k) \cdot p_i = I_k \cdot p_i = 0$$

$$\Rightarrow (\underline{\Delta}(x_0 + \sum_i x_i p_i) - y) \cdot p_i = \frac{(\underline{\Delta} x_0 - y)}{-I_0} \cdot p_i + \underline{\Delta} x_i p_i \cdot p_i = 0$$

$$\rightarrow x_i = \frac{I_0 \cdot p_i}{p_i \cdot \underline{\Delta} p_i} \quad \textcircled{2}$$

Nützliche Beziehungen zwischen I und p :

- Orthogonalität Residuum Abstiegsrichtung: $i = 1 \dots k$

$$p_i \cdot I_k = p_i \cdot (y - \underline{\Delta}(x_0 + \sum_{i=1}^k x_i p_i))$$

• Orthogonalität Residuum Absteigend: $i=1..k$

$$p_i \cdot I_k = p_i \cdot \left(y - \sum_{j=1}^k b_{ij} p_j \right)$$

$$\stackrel{(1)}{=} p_i \cdot I_0 - \sum_{j \neq i} b_{ij} p_i \cdot p_j = p_i \cdot I_0 - \sum_{j \neq i} b_{ij} p_i \cdot p_i$$

$$\stackrel{(2)}{=} p_i \cdot I_0 - \frac{I_0 \cdot p_i}{p_i \cdot p_i} p_i \cdot \sum_{j \neq i} b_{ij} p_i = 0 \quad \boxed{I_0 \cdot I_k = 0 \quad i=1..k} \quad (3)$$

→ Absteigendungen werden nur k mal durchlaufen

• Orthogonalität der Residuen: $i=1..k, j=1..k$

$$p_{in} = I_i + \sum_{j \neq i} b_{in} p_j \rightarrow I_i = p_{in} - \sum_{j \neq i} b_{in} p_j$$

$$I_i \cdot I_j = p_{in} \cdot I_j - b_{in} p_i \cdot I_j \stackrel{(3)}{=} 0 \quad \boxed{I_0 \cdot I_j = \delta_{0j} I_0 \cdot I_j} \quad (4)$$

$$\cdot I_i \cdot \sum_{j \neq i} p_j = (p_{in} - \sum_{j \neq i} b_{in} p_j) \cdot \sum_{j \neq i} p_j \stackrel{(1)}{=} 0$$

$$\boxed{I_i^T A^T I_0 = 0 \quad i=1..k} \quad (5)$$

• CG-Verfahren Algorithmus: (I_x =aktuelle Iteration)

$$x_{k+1} = x_k + \alpha_{k+1} p_{k+1} \text{ mit } p_{k+1} = I_k + \sum_{j=1}^k b_{j+1} p_j$$

Unbekannt: $p_{k+1} / \beta_{k+1}, x_{k+1}$

• Forderung aufgrund Vervierfachung/ π -Orthogonalität: $I_{k+1} \perp p_j \quad j \leq k$

$$p_{k+1} \perp p_j = I_k \cdot p_j + \sum_{i=1}^k b_{i+1} p_i \cdot p_j = I_k \cdot p_j + b_{k+1} p_k \cdot p_j \stackrel{(1)}{=} 0$$

$$\rightarrow \begin{cases} j=i \leq k \text{ da } I_k \cdot p_j \stackrel{(1)}{=} 0 \quad b_{i+1} \stackrel{(1)}{=} 0 \\ j=i=k \quad I_k \cdot p_k \stackrel{(1)}{=} 0 + b_{k+1} p_k \cdot p_k \stackrel{(1)}{=} 0 \end{cases} \rightarrow \boxed{\beta_{k+1} = \frac{-I_k \cdot p_k}{p_k \cdot p_k}}$$

$$\Rightarrow p_{k+1} = I_k + \beta_{k+1} p_k$$

• Berechnung x_{k+1} :

$$\alpha_{k+1} = \frac{I_0 \cdot p_{k+1}}{p_{k+1} \cdot p_{k+1}}$$

$$I_0 \cdot p_{k+1} = (y - \sum_{i=1}^k x_i I_i) \cdot p_{k+1} = (I_k - \sum_{i=1}^k x_i I_i) \cdot p_{k+1}$$

$$\stackrel{(3)}{=} I_k \cdot p_{k+1} = I_k \cdot (I_k + \sum_{j=1}^k b_{j+1} p_j) \stackrel{(3)}{=} I_k \cdot I_k$$

$$\alpha_{k+1} = \frac{I_0 \cdot I_0}{p_{k+1} \cdot p_{k+1}}$$

$$\cdot "Vervierfachung" \quad \beta_{k+1} = \frac{-I_k \cdot p_k}{p_k \cdot p_k}$$

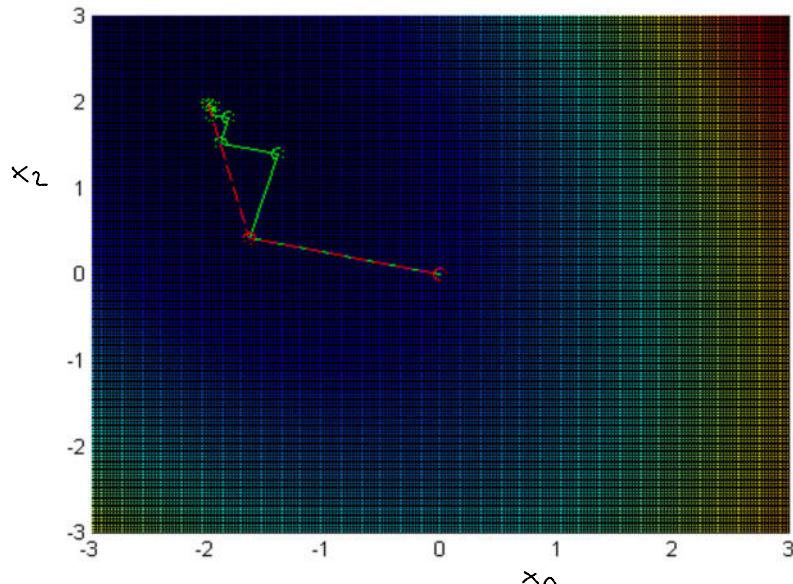
$$I_k = I_{k-1} - x_k p_k \rightarrow \frac{p_k}{p_k} = \frac{-I_k + I_{k-1}}{\alpha_k} \quad \boxed{I_k \cdot p_k = -\frac{1}{\alpha_k} I_k \cdot I_k} \quad (6)$$

$$p_k = I_{k-1} + \beta_{k-1} p_{k-1} \rightarrow p_k \perp p_k = (I_{k-1} + \beta_{k-1} p_{k-1}) \cdot (-I_k + I_{k-1}) \frac{1}{\alpha_k}$$

$$\stackrel{(2)(3)}{=} I_{k-1} \cdot I_{k-1} \frac{1}{\alpha_k} \quad (7)$$

$$\beta_{k+1} = \frac{I_0 \cdot I_k}{p_k \cdot p_k} = \frac{I_0 \cdot I_k}{I_{k-1} \cdot I_{k-1}}$$

- vergleicht Gradientenverfahren (grün) vs. CG-Verfahren (rot) für obiges 2D-Problem:
 - CG-Verfahren konvergiert in 2 Schritten, Gradientenverfahren in ca. 30



- Anmerkung zur λ -Orthogonalität:
Würde man den Contourplot so drehen/strecken, dass die Höhenlinien kreisförmig verlaufen, ständen die Suchrichtungen p_1 und p_2 bzgl. der (x_1, x_2) Basis senkrecht aufeinander

• Algorithmus CG-Verfahren

```
 $x_0 = 0, k=0, I_0 = y, p_0 = I_0, \beta_0 = 0$ 
WHILE ( $\frac{\|I_k\|}{\|y\|} > TOL \wedge k < k_{MAX}$ )
```

$$p_{k+1} = I_k + \beta_{k+1} p_k$$

$$\alpha_{k+1} = \frac{I_k \cdot I_k}{p_{k+1} \cdot p_{k+1}}$$

$$x_{k+1} = x_k + \alpha_{k+1} p_{k+1}$$

$$I_{k+1} = I_k - x_{k+1} p_{k+1}$$

$$\beta_{k+1} = \frac{I_{k+1} \cdot I_{k+1}}{I_k \cdot I_k}$$

$$k = k+1$$

END

• Algorithmus Gradienten-Verfahren:

$$k = 0$$

$$x_0 = x_s \quad x_s = \text{Startwert}$$

$$I_0 = y - \underline{x}_0$$

```
WHILE ( $\frac{\|I_k\|}{\|y\|} > TOL \wedge k < k_{MAX}$ )
```

$$\alpha_k = \frac{I_k \cdot I_k}{I_k \cdot \underline{x}_k}$$

$$x_{k+1} = x_k + \alpha_k I_k$$

$$I_{k+1} = y - \underline{x}_{k+1}$$

$$k = k+1$$

END